Makine Öğrenmesine Giriş: Boyut İndirgeme ve Kümeleme

1. PCA (Temel Bileşen Analizi)

PCA, çok sütunlu veriyi en az bilgi kaybıyla daha az sütuna indiren bir yöntemdir. Veride en çok değişimin olduğu yönü bulur ve buna Bileşen 1 adını verir. Bileşen 2, Bileşen 1'e dik olan ve kalan değişimi taşıyan yöndür.

PCA'dan önce sütunlar StandardScaler ile ölçeklenmelidir. Ölçekleme yapılmazsa değerleri büyük olan sütun sonucu belirler. PCA bileşenleri birbirinden bağımsızdır, bu yüzden aralarındaki korelasyon yaklaşık sıfırdır.

explained_variance_ratio_ değeri, her bileşenin toplam bilginin yüzde kaçını taşıdığını gösterir. Örneğin 0,95 değeri, bilginin %95'inin tek bileşende toplandığı anlamına gelir.

2. t-SNE

t-SNE, yüksek boyutlu veriyi görselleştirmek için iki boyuta indiren doğrusal olmayan bir yöntemdir. Yakın noktaların yakın kalmasını hedefler. Eksen değerlerinin kendisi yorumlanmaz, sadece kümelerin ayrışıp ayrışmadığına bakılır.

t-SNE'de perplexity parametresi satır sayısından küçük olmalıdır. Varsayılan değer 30'dur. 30 satırlık bir veride perplexity değeri 5 gibi küçük seçilmelidir, aksi halde ValueError alınır.

t-SNE sadece sayısal sütun kabul eder. Şehir gibi yazı sütunları önce frekans kodlama veya one-hot encoding ile sayıya çevrilmelidir. Label encoding şehirler arasında sahte bir sıralama yarattığı için önerilmez.

Veri Temizliği ve Korelasyon

3. Eksik ve Sıfır Değerler

Gelir veya harcama gibi sütunlarda sıfır değeri çoğu zaman eksik veriyi temsil eder. Sıfırlı satır sayısı toplamın %5'inden azsa satırları silmek uygundur. Daha fazlaysa medyan ile doldurmak veri kaybını önler.

NaN değerler isna().sum() ile sayılır ve dropna() ile temizlenir. Silme işleminden sonra kalan satır sayısı kontrol edilmelidir.

4. Korelasyon

Pearson korelasyonu iki sütun arasındaki doğrusal ilişkiyi ölçer. 1'e yakın değer güçlü pozitif, -1'e yakın değer güçlü negatif ilişki demektir. 0'a yakın değer doğrusal ilişki olmadığını gösterir.

p-değeri 0,05'ten küçükse ilişki istatistiksel olarak anlamlıdır. p-değeri etkinin büyüklüğünü değil, yalnızca var olup olmadığını gösterir. Korelasyon nedensellik anlamına gelmez.

Örnek veri setinde Arge Harcaması ile Kâr arasında güçlü pozitif ilişki bulunmuştur. Arge harcaması arttıkça kâr da artmaktadır.

RAG (Retrieval-Augmented Generation)

5. RAG Nedir?

RAG, bir dil modelinin cevabını kendi bilgisinden değil, aranan belgelerden bulunan parçalara dayandırarak üretmesi yöntemidir. Böylece model, eğitimi sırasında görmediği özel belgeler hakkında da soruları yanıtlayabilir.

Akış beş adımdan oluşur: belgeyi oku, metni parçalara böl, parçaları embedding ile sayısal vektörlere çevir, vektörleri ChromaDB gibi bir veritabanına kaydet, soru geldiğinde en yakın parçaları bulup dil modeline ver.

Parça boyutu (chunk_size) genellikle 500 ile 1000 karakter arasında seçilir. chunk_overlap, ardışık parçalar arasındaki ortak karakter sayısıdır ve anlam kopmasını azaltır.

6. Ücretsiz Araçlar

Ollama, açık kaynaklı modelleri bilgisayarda yerel olarak çalıştırır ve API ücreti gerektirmez. Groq ve Google Gemini ücretsiz API kotası sunar. Hugging Face, embedding modelleri için kullanılır. Türkçe metinler için çok dilli paraphrase-multilingual-MiniLM-L12-v2 modeli uygundur.